



Машинное обучение для решения исследовательских и инженерных задач в науках о Земле

Михаил Криницкий

к.т.н., н.с.

Институт океанологии РАН им. П.П. Ширшова

Лаборатория взаимодействия океана и атмосферы и
мониторинга климатических изменений (ЛВОАМКИ)

ПЛАН ЛЕКЦИИ

- ИНС: повторение теории
- ИНС: практика

A N N
A N N

Линейная регрессия

$$y_i \sim \mathcal{N}(\mu(\theta, x_i), \sigma^2)$$

$$\eta_i = \theta \cdot x_i$$

$$\mu(\theta, x_i) = \eta_i$$

Логистическая регрессия

$$y_i \sim \mathcal{B}(p(\theta, x_i))$$

$$p(\theta, x_i) \propto \exp(\theta_1 \cdot x_i)$$

$$\eta_i^1 = \theta_1 \cdot x_i = \ln \frac{p_i}{1 - p_i}$$

$\hat{g}^{-1} = \text{sigmoid}$

$$p(\theta_1, x_i) = \text{sigmoid}(\eta_i^1) = \frac{1}{1 + \exp(-\eta_i^1)}$$

Мультиномиальная логистическая регрессия

$$y_{ik} \sim \mathcal{B}(p_k(\theta, x))$$

$$p_k(\theta, x_i) \propto \exp(\theta_k \cdot x_i)$$

$$\eta_i^k = \theta_k \cdot x_i = \ln p_{ik} + C$$

$\hat{\eta} \approx \text{softmax}$

$$p_k(\theta_1, x_i) = \text{softmax}(\eta_i^k, \{\eta_i^k\}) = \frac{\exp \eta_i^k}{C^*}$$

Альтернативно (некорректно, но легче понять):

Обобщенные линейные модели: модели, в которых **мат.ожидание параметра распределения** целевой переменной вычисляется как некоторая **функция $g^{-1}(\cdot)$** от линейной функции η признакового описания объектов (событий) x_i

$g(\cdot)$ – т.н. функция связи (link function)

Регрессия

$$y_i \sim \mathcal{N}(\mu(\theta, x_i), \sigma^2)$$

$$\eta_i = \theta \cdot [f_1(x_i^{(1)}), f_2(x_i^{(2)}), f_3(x_i^{(3)}) \dots f_f(x_i^{(f)})]$$

$\mu(\theta, x_i) = \eta_i$

Бинарная классификация

$$y_i \sim \mathcal{B}(p(\theta, x_i))$$

$$p(\theta, x_i) \propto \exp(\theta_1 \cdot x_i)$$

$$\eta_i^1 = \theta \cdot [f_1(x_i^{(1)}), f_2(x_i^{(2)}), f_3(x_i^{(3)}) \dots f_f(x_i^{(f)})] = \ln \frac{p_i}{1 - p_i}$$

$p(\theta_1, x_i) = \text{sigmoid}(\eta_i^1) = \frac{1}{1 + \exp(-\eta_i^1)}$

Мультиномиальная классификация

$$y_{ik} \sim \mathcal{B}(p_k(\theta, x))$$

$$p_k(\theta, x_i) \propto \exp(\theta_k \cdot x_i)$$

$$\eta_i^k = \theta \cdot [f_1(x_i^{(1)}), f_2(x_i^{(2)}), f_3(x_i^{(3)}) \dots f_f(x_i^{(f)})] = \ln p_{ik} + C$$

$p(\theta_1, x_i) = \text{softmax}(\eta_i^k, \{\eta_i^k\}) = \frac{\exp \eta_i^k}{C^*}$

Альтернативно (некорректно, но легче понять):

Обобщенные аддитивные модели – это обобщенные линейные модели, в которых в качестве признаков объектов x_i выступают некоторые гладкие (часто нелинейные) функции этих признаков

Как зависит вид функции потерь от вида функции связи?

НИКАК

вид функции потерь $\mathcal{L}(\mathcal{T}, \theta)$ зависит от вида распределения целевой переменной y_i , но не от вида функции связи $g(\cdot)$


- обратная функция связи $g^{-1}(\cdot)$ должна отображать R^1 (множество значений произвольной линейной функции $\theta \cdot x_i$) на множество параметров распределения переменной y_i
- вычисление параметра (параметров) распределения переменной y_i в модели производится согласно принципу GLM
- при таких условиях вычисление правдоподобия выборки \mathcal{T} производится независимо от вида функции связи $g(\cdot) \Rightarrow$ вычисление функции потерь в подходе максимизации правдоподобия также производится независимо от вида функции связи $g(\cdot)$

previous [Линейные модели](#) | [ML4ES](#)

Почти всегда в случае задачи регрессии: $y \sim \mathcal{N}(\mu, \sigma^2)$

ЛР:

$$\mu_{y_i} = \theta \cdot x_i + \theta_0$$



previous [Lecture 4](#) в случае задачи регрессии: $y \sim \mathcal{N}(\mu, \sigma^2)$


ЛР:

$$\mu_{y_i} = \theta \cdot x_i + \theta_0$$

$\text{g} \rightarrow \mathcal{G}$

GLM:

$$\mu_{y_i} = \sigma(\theta \cdot x_i + \theta_0)$$



previous [Лекция 4](#) в случае задачи регрессии: $y \sim \mathcal{N}(\mu, \sigma^2)$

ЛР:


$$\mu_{y_i} = \theta \cdot x_i + \theta_0$$

GLM:

$$\mu_{y_i} = \sigma(\theta \cdot x_i + \theta_0)$$

GAM:

$$\mu_{y_i} = \sigma\left(\theta \cdot [f_1(x_i^{(1)}), f_2(x_i^{(2)}), f_3(x_i^{(3)}) \dots f_f(x_i^{(f)})] + \theta_0\right)$$



previous
Почти всегда в случае задачи регрессии: $y \sim \mathcal{N}(\mu, \sigma^2)$

ЛР:

$$\mu_{y_i} = \theta \cdot x_i + \theta_0$$

GLM:


$$\mu_{y_i} = \phi(\theta \cdot x_i + \theta_0)$$

GAM:

$$\mu_{y_i} = \sigma \left(\theta \cdot [f_1(x_i^{(1)}), f_2(x_i^{(2)}), f_3(x_i^{(3)}) \dots f_f(x_i^{(f)})] + \theta_0 \right)$$

ИНС:

$$\mu_{y_i} = \phi \left(\theta_0^{(2)} + \theta^{(2)} \cdot \phi \left(\theta_0^{(1)} + \theta^{(1)} \cdot x_i \right) \right)$$



previous lesson M4ES

Почти всегда в случае задачи регрессии: $y \sim \mathcal{N}(\mu, \sigma^2)$

ЛР:

$$\mu_{y_i} = \theta \cdot x_i + \theta_0$$

GLM:


$$\mu_{y_i} = \phi(\theta \cdot x_i + \theta_0)$$

GAM:


$$\mu_{y_i} = \sigma\left(\theta \cdot [f_1(x_i^{(1)}), f_2(x_i^{(2)}), f_3(x_i^{(3)}) \dots f_f(x_i^{(f)})] + \theta_0\right)$$

ИНС:

$$\mu_{y_i} = \phi\left(\theta_0^{(3)} + \theta^{(3)} \cdot \phi\left(\theta_0^{(2)} + \theta^{(2)} \cdot \phi\left(\theta_0^{(1)} + \theta^{(1)} \cdot x_i\right)\right)\right)$$



Искусственные нейронные сети



Вид ИНС:


многослойный перцептрон (multilayer perceptron, MLP)

Feedforward NN (FNN, сеть прямого распространения)


полносвязная ИНС (Fully-connected NN, FCNN)

MLP

$$\xi_i = \sigma \left(\theta_0^{(3)} + \theta^{(3)} \cdot \phi \left(\theta_0^{(2)} + \theta^{(2)} \cdot \phi \left(\theta_0^{(1)} + \theta^{(1)} \cdot x_i \right) \right) \right)$$



MLP



$$\tilde{z}^{(1)} = x^* \cdot \theta^{(1)*}$$

$$\theta^{(1)} = \phi(z^{(1)})$$

$$x$$

$$z \sim 1 \times f^{(1)}$$


$$z \sim l \times c^{(1)}$$

$$\theta \sim \phi(z) \sim z$$

$$\theta \sim l \times c^{(1)}$$

$$l \theta$$

MLP



$$\begin{aligned} c^{(1)} &\sim \mathcal{N}(0, I) \\ z^{(1)} &= \theta^{(1)} \cdot x + b^{(1)} \\ a^{(1)} &= f(z^{(1)}) \\ \theta^{(2)} &= \mathcal{N}(0, I) \\ z^{(2)} &= a^{(1)} \cdot \theta^{(2)} + b^{(2)} \\ a^{(2)} &= f(z^{(2)}) \\ \theta^{(3)} &= \mathcal{N}(0, I) \\ z^{(3)} &= a^{(2)} \cdot \theta^{(3)} + b^{(3)} \\ a^{(3)} &= f(z^{(3)}) \end{aligned}$$

$\theta^{(1)} \sim \mathcal{N}(0, I)$


$\theta^{(2)} \sim \mathcal{N}(0, I)$

$\theta^{(3)} \sim \mathcal{N}(0, I)$

$b^{(1)}, b^{(2)}, b^{(3)} \sim \mathcal{N}(0, I)$

$x \sim \mathcal{N}(0, I)$

MLP



$$\theta^{(2)*} \sim N \times (C^{(2)} + 1)$$

$$\theta^{(3)*} = \theta^{(2)*} \cdot \theta^{(3)*}$$

$$z^{(3)} \sim N \times (C^{(2)} + 1) \times C^{(3)}$$

$$\xi \sim G(z^{(3)})$$

$$\xi \sim z^{(3)}$$

$$z^{(3)} \sim N \times C^{(3)}$$

$$\theta^{(3)*} \sim (C^{(2)} + 1) \times C^{(3)}$$