

DEEP LEARNING for Earth Sciences

Святослав Елизаров

Институт океанологии им. П.П. Ширшова РАН

ОБУЧЕНИЕ НЕЙРОННЫХ СЕТЕЙ

Для всех описанных ранее линейных моделей функция потерь была выпуклой. Выпуклая функция обладает множеством замечательных свойств, наиболее важными из которых для нас являются:


1. Функция непрерывна и дифференцируема на всём интервале за исключением не более чем счётного множества точек и дважды дифференцируема почти всюду.
2. Локальный минимум является глобальным.

Таким образом мы можем применять основанные на вычислении градиента методы, не боясь застрять в локальном минимуме. Так же важным является то, что мы можем вычислить Гессиан, если необходимо.

Градиент – обобщение производной на многомерный случай. Это вектор, показывающий направления роста функции и по модулю равный скорости роста. Обозначается $\nabla f(x)$.

Градиентный спуск – простейший метод численной оптимизации: суть метода в последовательном движении в направлении противоположном градиенту.

ГРАДИЕНТНЫЙ СПУСК



$$\theta_{n+1} = \theta_n - \lambda \nabla f(\theta)$$

Где θ_n – вектор параметров функции f на итерации n .

λ – learning rate, может быть как константой, так и функцией от номера итерации.

НЕВЫПУКЛЫЙ СЛУЧАЙ

Для искусственных нейронных сетей в общем виде требование выпуклости функции потерь не соблюдается (почему?). При обучения сети нам предстоит столкнуться со следующими проблемами:

1. Наличие множества локальных минимумов
2. Множество глобальных минимумов
3. Седловые точки
4. Миллионы параметров

Долгое время эти причины не позволяли использовать модели на основе искусственных нейронных сетей на практике.

В статье Kenji Kawaguchi, 2016. Deep Learning without Poor Local Minima доказано, что для линейной глубокой сети (три и более слоёв) справедливы следующие утверждения:

- Каждый локальный минимум является глобальным
- Каждая критическая точка, не являющаяся глобальным минимумом, является седловой точкой

НАЛИЧЕ МНОЖЕСТВА ЛОКАЛЬНЫХ МИНИМУМОВ

В статье Kenji Kawaguchi, 2016. Deep Learning without Poor Local Minima доказано, что для линейной глубокой сети (три и более слоёв) справедливы следующие утверждения:


- Каждый локальный минимум является глобальным
- Каждая критическая точка, не являющаяся глобальным минимумом, является седловой точкой

Эти же утверждения справедливы для сетей с активацией типа Relu, в предположении что карты активации не зависят от входа (нереалистичное предположение)

НАЛИЧЕ МНОЖЕСТВА ЛОКАЛЬНЫХ МИНИМУМОВ

В статье LeCun et al., 2014. The Loss Surfaces of Multilayer Networks проводится исследование ландшафта функции потерь и показывается, что вероятность попадания в плохой локальный минимум убывает с увеличением количества слоёв.


НАЛИЧЕ МНОЖЕСТВА ЛОКАЛЬНЫХ МИНИМУМОВ




1. В статье Hochreiter, S., Schmidhuber, J. (1997). Flat minima. Neural Computation проводится исследование ландшафта функции потерь глубокой нейронной сети и вводятся понятия плоского и острого минимумов.
2. В работе L Dinh et al. (2017) Sharp Minima Can Generalize For Deep Nets вводится строгое определение для двух типов минимумов и показано, что в некоторых случаях сети с Relu-активациями не теряют обобщающей способности даже при попадании в sharp minimum

Седловой называется такая критическая точка функции, которая не является её экстремумом. Достаточное (но не необходимое!) условие того, что точка седловая: Гессиан в этой точке является неопределённой квадратичной формой.


СЕДЛОВЫЕ ТОЧКИ



(a) $f(x) = x^3$



(b) $f(x) = x_1^2 - x_2^2$



(c) $f(x) = x_1^3 - 3x_1x_2^2$

Идеи?




Добавим шум к градиенту. Если представить шарик, который катится по поверхности, то велика вероятность, что он скатится из седловой точки, если будет двигаться с небольшими случайными флуктуациями.

$$\theta_{n+1} = \theta_n - \lambda \nabla f(\theta) + \epsilon$$

Где $\epsilon \sim N(0, 1)$, т.е. Гауссовский шум.

Rong Ge et al., 2015. Escaping From Saddle Points – Online Stochastic Gradient for Tensor Decomposition

СЕДЛОВЫЕ ТОЧКИ



- Модели на основе искусственных нейронных сетей могут иметь сотни тысяч или даже миллионы параметров.
- Чтобы обучить такую модель потребуется существенный объём данных.

Существуют теоретические оценки, но они сильно завышены и не могут быть применены на практике.

МЕТОДЫ ОПТИМИЗАЦИИ

Ищем локальный экстремум, идем вдоль градиента

$$W_{i+1} = W_i - \lambda \nabla L(W_i, X, y)$$



При большом наборе обучающих данных алгоритм будет работать крайне медленно. Более того, данные могут просто не поместиться в память.

На практике производят корректировку коэффициентов сети с использованием градиента, который аппроксимируется градиентом функции потерь, вычисленной только на случайном подмножестве обучающей выборки (mini batch).

Количество объектов для вычисления градиента выбирается исходя из объема памяти который имеется (максимально заполняем память) или выбирается с помощью кросс-валидации.

$$L(W) = \frac{1}{N} \sum_i^N L_i(W, x_i, y_i)$$


$$\nabla_W L(W) = \frac{1}{N} \sum_i^N \nabla_W L_i(W, x_i, y_i)$$

Исследование Keskar et al. (2016). On large-batch training for deep learning: Generalization gap and sharp minima показывает взаимосвязь между размером минибатча и вероятностью попасть в sharp minimum


Name	Training Accuracy		Testing Accuracy	
	SB	LB	SB	LB
F_1	99.66% \pm 0.05%	99.92% \pm 0.01%	98.03% \pm 0.07%	97.81% \pm 0.07%
F_2	99.99% \pm 0.03%	98.35% \pm 2.08%	64.02% \pm 0.2%	59.45% \pm 1.05%
C_1	99.89% \pm 0.02%	99.66% \pm 0.2%	80.04% \pm 0.12%	77.26% \pm 0.42%
C_2	99.99% \pm 0.04%	99.99% \pm 0.01%	89.24% \pm 0.12%	87.26% \pm 0.07%
C_3	99.56% \pm 0.44%	99.88% \pm 0.30%	49.58% \pm 0.39%	46.45% \pm 0.43%
C_4	99.10% \pm 1.23%	99.57% \pm 1.84%	63.08% \pm 0.5%	57.81% \pm 0.17%

Точность на тренировочной и тестовой выборке для
большого(LB) и маленького(SB) батчей

Что будет с Vanilla SGD если линии уровня функции потерь выглядят так:




Что будет с Vanilla SGD если линии уровня функции потерь выглядят так:



Как можно улучшить алгоритм?

Не забываем о локальных минимумах и седловых точках!



Как можно улучшить алгоритм?

Если в случае градиентного спуска мы представляли человека, спускающегося с высокой горы, то в случае импульсного метода с горы скатывается тяжелый железный шар. На направление и скорость движения шара влияет не только тот рельеф, который он преодолевает в данный момент, но и его предыдущее состояние.

SGD:


$$W_{t+1} = W_t - \lambda \nabla L(W_t, \dots)$$

Импульсный метод

$$v_{t+1} = \rho v_t + \nabla L(W_t, \dots)$$

$$W_{t+1} = W_t - \alpha v_{t+1}$$

Метод даёт существенный прирост в скорости сходимости. Более подробно про метод можно прочесть в онлайн-журнале distill.pub:
Gabriel Goh 2017. Why Momentum Really Works



$$Cache_{t+1} = Cache_t + \nabla L(W_t, \dots)$$

$$W_{t+1} = W_t - \frac{\lambda \nabla L(W_t, \dots)}{\sqrt{Cache_{t+1} + 1e^{-10}}}$$

Масштабирование шага для каждого параметра. Редкие признаки получаю больше внимания при оптимизации.


Какие могут быть проблемы? Как их решить?

$$Cache_{t+1} = \gamma Cache_t + (1 - \gamma) \nabla L(W_t, \dots)$$

$$W_{t+1} = W_t - \frac{\lambda \nabla L(W_t, \dots)}{\sqrt{Cache_{t+1} + 1e^{-10}}}$$

γ - Параметр затухания для истории градиентов, учитываем только окно недавних градиентов

$$Adam = RMSProp + Momentum$$



- SGD
- SGD+Momentum
- RMSProp
- Adam

